



西北工业大学
NORTHWESTERN POLYTECHNICAL UNIVERSITY



西北工业大学
NORTHWESTERN POLYTECHNICAL UNIVERSITY

一种面向复杂场景的红外-可见光 多模态小目标检测方法

2025.12.30

组长：宋抗非
组员：赵红玉 胡佳傲 赵网 李雨博



目 录

01 研究背景

Research Background

02 研究方法

Research methods

03 实验与分析


Experiment and Analysis

04 总结与展望

Summary and Prospect

研究背景

在遥感监测与无人机巡检等应用中，目标检测是实现自动感知与智能分析的重要基础。然而，复杂环境条件给检测任务带来了较大挑战。



可见光图像



红外图像

单一模态在遥感场景中往往存在明显局限：

可见光图像细节丰富，但易受光照变化、阴影和背景干扰；

红外图像对目标更加敏感，但纹理和结构信息相对不足。



研究现状：多模态融合仍面临关键挑战

(1) 特征分布差异大

不同模态在亮度、纹理与语义表达上存在显著差异，直接融合易引入噪声

(2) 小目标信息易丢失

遥感场景中目标尺度小、密集，多尺度融合过程中细节容易被削弱

(3) 融合结构复杂度高

现有检测方法往往依赖复杂模块，计算开销大，难以兼顾效率与性能



研究动机与研究思路

研究目标

- (1) 充分挖掘红外与可见光的互补信息
- (2) 提升复杂场景下的小目标检测性能
- (3) 在保证精度的同时兼顾计算效率

研究思路

- 从**特征建模**角度增强多模态语义表达能力
- 从**多尺度融合**角度强化小目标细节信息
- 从**结构设计**角度提升特征融合效率

基于上述思路，本研究设计了一种高效的多模态目标检测框架。

研究背景

研究方法

实验与分析

总结与展望

基线多模态目标检测框架设计

整体结构

双分支 Backbone: 红外 / 可见光分别提取特征

特征级融合: 在中高层进行跨模态信息整合


多尺度检测 Head: 输出不同尺度目标预测结果

多模态策略

低层(P3): 强调空间细节 (RGB)

中高层(P4、P5): 融合红外与可见光语义信息

避免早期融合带来的噪声干扰



研究背景

研究方法

实验与分析

总结与展望

改进后的多模态目标检测框架

(1) AGCSPB: 多模态特征建模增强

引入注意力与门控机制

提升复杂背景下的语义判别能力


(2) SSOEP: 小目标增强

针对上采样对齐与尺度失配问题

强化小目标与细粒度结构信息

(3) GSConvE: 高效特征融合

提升特征多样性与通道交互



AGCSPB: 注意力门控的多模态特征建模模块

CGLU (CVPR2024-TransNeXt: Robust Foveal Visual Perception for Vision Transformers)

SHSA (CVPR2024-SHViT: Single-Head Vision Transformer with Memory Efficient Macro Design)

原始 CBS 仅进行局部卷积建模

难以区分复杂背景下的有效多模态特征

引入注意力与门控机制 (AGCBS)


强化关键信息, 抑制冗余干扰

提升多模态高层语义表达能力

增强复杂场景下的目标判别性

局部建模 → 全局建模

无选择 → 有选择





SSOEP:软对齐小目标增强金字塔

SNI (ECCV2024-Rethinking Features-Fused-Pyramid-Neck for Object Detection)

SPDConv (ECML2022-A New CNN Building Block for Low-Resolution Images and Small Objects)



CSPO (AAAI2024-Omni-Kernel Network for Image Restoration)

SNI (软最近邻插值上采样)

对上采样后的局部冗余响应进行约束与结构归一化，
减少复制带来的特征放大效应，提高尺度对齐稳定性。

SPDConv (空间到深度卷积)

在结构稳定的特征基础上进行受控下采样与重排，
在压缩空间分辨率的同时保留关键结构信息，提升特征表达效率。



SSOEP:软对齐小目标增强金字塔

SNI (ECCV2024-Rethinking Features-Fused-Pyramid-Neck for Object Detection)



SPDConv (ECML2022-A New CNN Building Block for Low-Resolution Images and Small Objects)

CSPO (AAAI2024-Omni-Kernel Network for Image Restoration)

CSPO（结合CSP思想的全方位多尺度核模块）

通过将 RGB 分支的细粒度空间信息与经 SNI-SPDConv 规范化后的对齐特征进行拼接，有效兼顾高分辨率细节与尺度一致性，为 CSPO 的多尺度建模提供可靠输入。

CSPO 进一步在此基础上增强对多尺度结构模式的表达能力。





GSConvE：增强型GSConv模块


GSConvE (JRTIP2024-Slim-neck by GSConv: a light-weight design for real-time detector architectures)

引入GSConvE 模块来替代标准卷积。

GSConvE引入了增强卷积分支

目的是在不显著增加计算量的情况下，加强通道之间的特征交互。

对于多模态、多尺度特征融合来说，这种高效的信息混合方式有助于提升整体融合效果。





数据集介绍



M3FD数据集



VEDAI512数据集

M3FD 是一个典型的红外-可见光双模态目标检测数据集，覆盖多场景、多光照与复杂背景条件，能够全面验证多模态特征互补与融合效果。

VEDAI512 是面向航空遥感场景的红外-可见光双模态小目标检测数据集，目标尺度小、背景复杂，对多尺度特征表达能力提出较高要求。

实验设置

表 1 实验环境与训练参数设置

项目	配置说明
操作系统	Linux
编程语言	Python 3.10.19
深度学习框架	PyTorch 2.2.0
CUDA 版本	CUDA 11.8
GPU 型号	NVIDIA A10
GPU 数量	4
单卡显存	24 GB
批大小 (Batch Size)	8
训练轮数 (M3FD)	200
训练轮数 (VEDAI512)	100
自动混合精度 (AMP)	未启用 (False)

对比实验

表 2 不同方法在 M3FD 数据集上的检测性能对比

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
YOLOv5n	83.8	64.6	73.1	46.4	7.1
YOLOv8n	83.6	68.9	74.9	51.4	8.1
YOLOv10n	76.8	70.2	76.0	47.1	6.5
YOLOv11n	80.8	65.6	71.9	50.4	6.3
YOLOv12n	80.8	64.4	70.9	44.4	5.8
YOLOv13n	73.9	55.6	61.9	38.5	6.2
RT-DETR	87.2	81.0	81.2	55.0	57.0
MMDetection-DS	85.0	66.2	75.4	50.2	19.8
Ours	88.9	68.4	78.9	51.9	16.9

表 3 不同方法在 VEDAI512 数据集上的检测性能对比

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
YOLOv8n	43.8	47.9	41.7	22.6	8.1
YOLOv9t	45.9	48.9	44.9	23.5	7.7
YOLOv10n	34.2	41.6	34.4	20.2	6.5
RT-DETR	55.4	53.6	49.3	27.6	57.0
Ours	54.3	56.9	49.1	27.1	16.9


消融实验

表 4 不同模块组合下的消融实验结果 (VEDAI512)

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
Baseline	40.1	48.0	43.6	23.5	6.3
Baseline+AGCSPB	39.6	46.9	45.4	23.0	10.3
Baseline+AGCSPB+SSOEP	41.4	55.8	48.2	26.0	16.2
Baseline+AGCSPB+SSOEP+GSConvE	54.3	56.9	49.1	27.1	16.9



效果可视化





分工

文献调研（宋抗非）

Baseline设计（赵红玉、胡佳傲）

数据集调研和收集（赵网）

AGCSPB（宋抗非）

SSOEP（李雨博、赵网）

GSCovE（胡佳傲）

实验（赵红玉）

PPT制作（李雨博）

论文撰写（宋抗非）

《多模态机器学习》

一种面向复杂场景的红外-可见光多模态小目标检测方法

宋抗非 赵红玉 胡佳傲 赵网 李雨博

摘要 针对复杂航空场景下红外与可见光多模态目标检测中存在的模态差异显著、小目标易丢失以及多尺度特征融合不稳定等问题，本文提出了一种多模态目标检测框架。该框架通过引入注意力门控特征建模模块增强多模态语义表达能力，设计对齐的小目标增强金字塔以缓解多尺度特征错配，并采用高效的特征融合结构提升特征交互质量。在保证计算效率的同时提升检测性能。在 M3FD 多模态数据集上，本文方法取得了 88.9% 的 Precision 和 78.9% 的 mAP@0.5，相较于基线模型分别提升 5.3% 和 5.3%；在 VEDAI512 数据集上，本文方法的 mAP@0.5 和 mAP@0.5:0.95 分别达到 49.1% 和 27.1%，相比基线模型提升 5.5% 和 3.6%。消融实验结果进一步验证了各改进模块在多模态特征建模与小目标检测中的有效性。实验表明，本文提出的方法在复杂背景和小目标场景下具有良好的鲁棒性与实用价值。

关键词 多模态目标检测；红外与可见光融合；小目标检测；多尺度特征融合；遥感图像

A Multi-modal Small Object Detection Method Based on Infrared and Visible Images for Complex Scenes

SongKangfei ZhaoHongyu HuJiaao ZhaoWang LiYubo

Abstract To address the challenges of significant modality discrepancies, small object degradation, and unstable multi-scale feature fusion in infrared and visible multi-modal object detection under complex aerial scenes, this paper proposes a novel multi-modal object detection framework. The proposed method enhances multi-modal semantic representation through an attention-gated feature modeling module, introduces a soft-aligned small object enhancement pyramid to alleviate scale mismatch, and adopts an efficient feature fusion strategy to balance detection accuracy and computational cost. On the M3FD dataset, the proposed method achieves a Precision of 88.9% and an mAP@0.5 of 78.9%, outperforming the baseline by 5.3% and 5.3%, respectively. On the VEDAI512 dataset, the proposed approach attains an mAP@0.5 of 49.1% and an mAP@0.5:0.95 of 27.1%, yielding improvements of 5.5% and 3.6% over the baseline. Ablation studies further demonstrate the effectiveness of each proposed module. Experimental results indicate that the proposed framework exhibits strong robustness and practical applicability in complex background and small object detection scenarios.

Keywords Multi-modal object detection; Infrared and visible fusion; Small object detection; Multi-scale feature fusion; Remote sensing imagery



总结

本文提出了一种面向红外-可见光场景的多模态目标检测框架，通过对特征建模、多尺度融合及特征融合结构的针对性改进，在保证计算效率的前提下提升了多模态融合质量与小目标检测性能。实验结果表明，该方法在多个数据集上均取得了稳定性能提升。


未来改进

1. 差异化模态特征建模

针对不同模态的成像特性，引入模态感知的差异化特征建模策略

2. 结合深度模态数据


在红外与可见光的基础上，未来可进一步引入深度（Depth）等模态信息，进一步构建模态目标检测框架。



可见光



红外



深度



谢谢