

一种面向复杂场景的红外-可见光多模态小目标检测方法

宋抗非 赵红玉 胡佳傲 赵网 李雨博

摘要 针对复杂航空场景下红外与可见光多模态目标检测中存在的模态差异显著、小目标易丢失以及多尺度特征融合不稳定等问题,本文提出了一种多模态目标检测框架。该框架通过引入注意力门控特征建模模块增强多模态语义表达能力,设计软对齐的小目标增强金字塔以缓解多尺度特征错配,并采用高效的特征融合结构提升特征交互质量,在保证计算效率的同时提升检测性能。在 M3FD 多模态数据集上,本文方法取得了 88.9% 的 Precision 和 78.9% 的 mAP@0.5,相较于基线模型分别提升 5.3% 和 5.3%;在 VEDAI512 数据集上,本文方法的 mAP@0.5 和 mAP@0.5:0.95 分别达到 49.1% 和 27.1%,相比基线模型提升 5.5% 和 3.6%。消融实验结果进一步验证了各改进模块在多模态特征建模与小目标检测中的有效性。实验表明,本文提出的方法在复杂背景和小目标场景下具有良好的鲁棒性与实用价值。

关键词 多模态目标检测; 红外与可见光融合; 小目标检测; 多尺度特征融合; 遥感图像

A Multi-modal Small Object Detection Method Based on Infrared and Visible Images for Complex Scenes

SongKangfei Zhaohongyu Hujiaao Zhaowang Liyubo

Abstract To address the challenges of significant modality discrepancies, small object degradation, and unstable multi-scale feature fusion in infrared and visible multi-modal object detection under complex aerial scenes, this paper proposes a novel multi-modal object detection framework. The proposed method enhances multi-modal semantic representation through an attention-gated feature modeling module, introduces a soft-aligned small object enhancement pyramid to alleviate scale mismatch, and adopts an efficient feature fusion strategy to balance detection accuracy and computational cost. On the M3FD dataset, the proposed method achieves a Precision of 88.9% and an mAP@0.5 of 78.9%, outperforming the baseline by 5.3% and 5.3%, respectively. On the VEDAI512 dataset, the proposed approach attains an mAP@0.5 of 49.1% and an mAP@0.5:0.95 of 27.1%, yielding improvements of 5.5% and 3.6% over the baseline. Ablation studies further demonstrate the effectiveness of each proposed module. Experimental results indicate that the proposed framework exhibits strong robustness and practical applicability in complex background and small object detection scenarios.

Keywords Multi-modal object detection; Infrared and visible fusion; Small object detection; Multi-scale feature fusion; Remote sensing imagery

1 引言

随着无人机平台、遥感成像设备以及深度学习技术的快速发展，基于航空图像的目标检测在智能巡检、交通管理、灾害监测和军事侦察等领域展现出广泛的应用前景^[1]。相较于地面视角图像，航空图像通常具有视角俯视^[2]、覆盖范围大以及目标尺度小等特点，图像中目标往往呈现出尺寸差异显著、背景复杂且分布密集的特征^[3]，这对目标检测算法的精度和鲁棒性提出了更高要求。

在航空图像目标检测任务中，小目标检测始终是一个具有挑战性的研究问题。一方面，小目标在图像中仅占据有限像素，其纹理和结构信息容易在多次下采样过程中被削弱甚至丢失^[4]；另一方面，复杂背景、光照变化以及遮挡等因素^[5]进一步加剧了目标与背景之间的区分难度。尽管近年来基于深度卷积神经网络的方法在目标检测领域取得了显著进展，但直接将通用检测框架应用于航空小目标场景时，仍然难以充分挖掘细粒度特征并保持稳定的检测性能。

为提升复杂场景下的目标感知能力，多模态成像技术逐渐受到关注。不同模态在成像机理和信息表达上具有天然互补性，例如，可见光图像在纹理细节和语义表达方面具有优势，而红外图像在弱光、夜间或复杂光照条件下能够更稳定地突出目标区域^[6]。通过融合多模态信息，有望在复杂环境中提升目标检测的鲁棒性和可靠性。然而，多模态特征在分布特性和尺度表达上的差异，使得其在深度网络中的有效融合仍然面临诸多挑战。

现有多模态目标检测方法主要关注特征级或决策级融合策略^[7]，但在实际应用中仍存在若干问题：其一，不同模态特征在多尺度金字塔结构中的对齐误差，容易导致融合特征不稳定，尤其对小目标检测不利；其二，部分融合方法依赖复杂的网络结构或高计算开销，限制了模型在实际工程场景中的部署；其三，在高层语义建模过程中，局部卷积操作难以充分捕获长程依赖关系，从而影响复杂背景下目标的判别能力。

基于上述分析，如何在多模态目标检测框架下，实现稳定的多尺度特征对齐、小目标信息的有效增强以及高效的特征融合与建模，仍然是一个值得深入研究的问题。围绕这些关键挑战，本文从网络结构设计角度出发，在多模态检测框架下对特征增强、尺度对齐和语义建模过程进行系统性改进，以期在保证计算效率的同时提升复杂场景下目标检测的整体性能。

2 网络结构与方法设计

2.1 整体网络框架设计

本文面向红外-可见光双模态输入场景，构建了一套多模态目标检测框架，并在该框架基础上进一步提出若干结构改进以提升复杂环境下的检测性能。整体设计遵循 YOLO 系列单阶段检测框架“Backbone-Neck-Head”的主干范式：Backbone 负责特征提取，Neck 负责多尺度特征融合，Head 负责在不同尺度特征上进行分类与定位预测。该范式具有端到端、推理高效等优势，适合在工程场景中部署。

(1) 基线多模态检测框架。

图 1 给出了本文构建的基线多模态目标检测框架。该框架参考 YOLO 系列单模态检测网络的结构组织方式，将单输入分支扩展为双模态并行分支：红外与可见光图像分别进入对应的 Backbone 分支进行层级特征提取。在中高层特征阶段，通过特征级融合（例如拼接/对齐后的融合）将两种模态的互补信息进行整合，随后送入 Neck 进行自顶向下与自底向上的多尺度融合，并在 Head 端输出多尺度检测结果。该基线框架在保持 YOLO 系列检测流程简洁性的同时，使网络具备利用多模态互补信息的能力，可作为后续改进方法的统一对照基准。

为进一步提升多模态检测性能，本文在上述基线框架基础上对网络结构进行了针对性改进。




图 1 基线多模态目标检测框架示意图

(2) 改进多模态检测框架。

在基线多模态检测框架的基础上，本文进一步围绕多模态特征建模与航空小目标检测中的关键问题，对网络结构进行了系统性改进，形成了最终的多模态目标检测框架，如图 2 所示。相较于基线框架，本文的改进主要体现在以下三个方面。

首先，针对高层特征中语义表达能力不足以及复杂背景下目标判别困难的问题，本文在特征建模阶段引入了 **Attention-Gated CSP Bottleneck (AGCSPB)** 模块，通过注意力机制与门控结构增强特征的全局建模能力与判别性表达。

其次，针对多尺度特征融合过程中小目标信息易丢失以及不同尺度特征对齐不稳定的问题，本文设计了 **Soft-aligned Small Object Enhancement Pyramid (SSOEP)**，通过软对齐上采样与小目标增强策略，对多尺度特征进行稳定融合并强化细粒度目标表征。

最后，针对自底向上特征融合路径中计算效率与特征多样性之间的权衡问题，本文在特征融合阶段引入了 **增强型 GSCovE 特征融合模块**，在保持较低计算开销的前提下提升特征表达的多样性与信息交互能力。

需要指出的是，本文提出的上述改进模块并非对现有结构的简单叠加，而是分别针对多模态互补建模、多尺度对齐与小目标细节保留等关键问题进行有针对性的设计。上述三个模块在整体框架中相互协同，共同构成本文提出的改进多模态目标检测方法，其具体结构与实现细节将在后续小节中分别进行详细介绍。




图 2 本文提出的改进多模态目标检测框架示意图

2.2 Attention-Gated CSP Bottleneck (AGCSPB)

在多模态目标检测任务中，红外与可见光图像在成像机理、对比度分布以及噪声形态等方面存在显著差异。可见光模态提供更丰富的纹理细节与结构信息，但在弱光、阴影或复杂背景下容易出现目标与背景混淆；红外模态对目标区域具有更稳定的响应，但在细粒度边缘与类别判别细节上相对不足。上述差异使得多模态特征融合并非简单叠加即可获得收益，反而可能引入跨模态冗余与噪声干扰，导致高层语义特征的判别性下降，进而影响复杂场景下的检测性能。

针对该问题，本文在基线框架的高层特征建模位置引入注意力与门控机制，提出 Attention-Gated CSP Bottleneck (AGCSPB) 模块。AGCSPB 在保持 CSP 结构高效性的同时，通过更强的全局建模与选择性信息传递，使网络能够在跨模态融合后的特征中自适应地强调有效响应、抑制无关噪声，从而提升多模态语义表示的鲁棒性。图 3 给出了 AGCSPB 与原始 C3k2 的结构对比，同时展示了 AGBottleneck 与 Bottleneck、以及 AGCBS 与 CBS 的差异。

2.2.1 设计动机

C3k2 属于典型的 CSP-style 模块，其基本思想是将输入特征在通道维度进行分流 (Split)，其中一部分通道直接旁路以保持梯度流与计算效率，另一部分通道进入若干 Bottleneck (或其变体) 进行特征变换，最终将两路特征拼接 (Concat) 并通过卷积融合得到输出。该结构在单模态检测任务中能够较好地平衡精度与速度，但在多模态融合场景中仍存在两个不足：

(1) **跨模态冗余与噪声容易在高层语义中累积。**多模态融合后特征同时包含纹理细节、热响应信息以及可能的伪响应（如热噪声、反射、高亮区域等）。传统 Bottleneck 以局部卷积为主，缺乏对全局依赖的显式




图 3 AGCSPB 与 C3k2 结构对比示意图

建模与对关键信息的选择性筛选，容易使无关响应随层数堆叠而被强化。

(2) **多模态信息的有效贡献具有场景相关性**。在不同光照、天气、背景条件下，不同模态的可靠性不同：某些场景下红外更可靠，某些场景下可见光更有判别力。若网络缺少动态调制机制，融合特征会以相对固定的方式传播，导致在部分场景下无法自适应地“用好更可靠的模态信息”。

为解决上述问题，本文提出的 AGCSPB 保留 C3k2 的 CSP 主体框架不变（即 Split-（变换分支堆叠）-Concat-Conv），将其中关键的变换单元由传统 C3k/Bottleneck 替换为引入注意力与门控的 AGBottleneck（内部由 AGCBS 组成）。该替换使得模型能够在较小的额外开销下获得更强的跨模态语义建模能力与自适应筛选能力。

2.2.2 从“局部堆叠”到“选择性建模”

传统 Bottleneck 通常由两次卷积变换（如 CBS-CBS）与残差连接构成，其主要作用是进行局部感受野的特征提取与非线性映射。该结构在单模态场景下能够逐步增强语义表达，但在多模态融合特征中，单纯的局部卷积堆叠容易出现以下现象：不同模态的冗余响应与局部噪声被反复传播，导致有效语义被稀释，尤其在背景纹理复杂或热噪声较强的区域更为明显。

为此，AGBottleneck 将 Bottleneck 内部的基础单元由 CBS 替换为 AGCBS，并保持残差路径，使得主分支的特征变换不仅具备局部建模能力，还具备跨区域的信息交互与选择性增强能力。换言之，Bottleneck 更偏向于“局部堆叠增强”，而 AGBottleneck 更强调“在增强之前先判断哪些信息值得增强”，从而更适合多模态融合后的复杂特征分布。

2.2.3 引入 SHSA 与 CGLU 的注意力门控机制

CBS 是检测网络中常用的基础卷积单元，通常由卷积、归一化与激活函数组成，其优势在于结构简单、计算高效，但其信息交互主要局限于局部卷积操作，对长程依赖与全局上下文的建模能力有限。在多模态融合特征中，目标区域往往需要结合更大范围的上下文信息进行判别（例如目标热响应与背景热源的区分、弱纹理下的边界确认等），仅依赖局部卷积容易导致误检与漏检。

本文提出的 AGCBS 在保持轻量化的前提下, 引入了两个关键设计: **SHSA** 与 **CGLU**。其中, SHSA 用于在特征变换过程中建立更强的跨区域信息交互, 使网络能够利用全局或长程上下文对融合特征进行重新组织; CGLU 作为门控结构, 对特征通道进行自适应调制, 从而实现对跨模态信息的选择性传递与抑制。直观而言, SHSA 提供“看得更远”的能力, 而 CGLU 提供“只放行有用信息”的能力。二者结合, 使得 AGCBS 相较于传统 CBS 更适合处理多模态融合后存在的冗余与噪声问题。

AGCSPB 在整体框架中主要承担高层语义建模与跨模态特征筛选的功能。通过将 C3k2 中的关键变换单元替换为引入注意力与门控机制的结构, AGCSPB 能够缓解多模态融合带来的冗余累积问题, 并提升在复杂背景、模态可靠性变化等情况下的自适应表达能力, 从而为后续的多尺度融合与检测头预测提供更鲁棒、更判别特征基础。

2.3 -aligned Small Object Enhancement Pyramid (SSOEP)

2.3.1 多模态小目标检测中的尺度对齐问题

在航空遥感场景下, 小目标通常仅占据极少的像素区域, 其空间结构和语义信息在多层特征提取与尺度变换过程中极易被削弱。对于多模态目标检测而言, 这一问题进一步被放大: 红外与可见光模态在成像分辨率、边缘响应以及目标显著性分布上存在差异, 使得不同尺度特征在上采样与下采样过程中更容易产生空间错配和语义不一致。

在传统特征金字塔结构中, 最近邻或双线性插值等上采样方式通常被用于实现自顶向下的特征对齐。然而, 这类硬插值方式在放大高层语义特征时, 会将单一像素值直接复制到多个位置, 从而引入明显的块状伪影与不连续响应。对于本身像素规模有限的小目标而言, 上述现象容易导致目标边界模糊、响应扩散甚至被背景噪声淹没, 进而影响后续检测头的判别能力。

2.3.2 软最近邻插值 (SNI) 机制

为缓解传统上采样方式在小目标检测中的对齐失真问题, 本文在特征金字塔结构中引入软最近邻插值 (Soft Nearest Neighbor Interpolation, SNI) 机制。与标准最近邻插值直接复制像素值不同, SNI 在完成空间放大操作后, 对插值结果进行幅值归一化, 从而在保持空间位置一致性的同时, 抑制由重复复制引入的响应放大效应。

图 4 对比展示了传统最近邻上采样与 SNI 的差异。可以观察到, 传统上采样会在放大后产生多个数值完全相同的响应单元, 而 SNI 通过缩放因子对响应强度进行约束, 使得放大后的特征在空间上更加平滑, 有利于后续特征融合与目标定位。




图 4 传统最近邻上采样与软最近邻插值 (SNI)

在多模态融合场景下, SNI 能够有效缓解不同模态特征在尺度扩展过程中产生的响应不一致问题, 使

得高层语义信息在传递至高分辨率特征图时保持更加稳定的空间分布，为小目标提供更可靠的语义支持。

2.3.3 空间到深度卷积（SPDConv）的小目标信息保留机制

在自底向上的特征融合路径中，传统步长卷积（Stride Convolution）通常通过局部区域聚合实现空间分辨率的降低，但该过程不可避免地伴随着信息丢失。对于小目标而言，其关键信息往往集中在局部区域，直接的下采样操作容易导致目标细节被平均化甚至完全丢失。

为此,本文引入空间到深度卷积(Space-to-Depth Convolution, SPDConv)作为下采样替代方案。SPDConv 通过将相邻空间位置的特征重新排列到通道维度中，实现空间分辨率降低的同时完整保留原始信息，从而避免了传统下采样带来的不可逆损失。




图 5 Stride Convolution 与 SPDConv 下采样方式对比

如图 5 所示，相比于步长卷积对局部区域进行数值聚合，SPDConv 能够将空间结构完整映射至通道维度，使网络在尺度变换后仍保留小目标的细粒度响应。这一特性在多模态融合特征中尤为重要，有助于维持跨模态小目标信息的一致性。

2.3.4 基于 CSP 的 OmniKernel 小目标增强结构（CSPO）

在完成多尺度特征对齐与信息保留之后，仍需对融合特征进行进一步增强，以提升小目标在复杂背景中的可分性。为此，本文在小目标增强路径中引入基于 CSP 结构的 OmniKernel 模块（CSPO）。

CSPO 延续 Cross Stage Partial 的设计思想，将输入特征划分为两部分：其中一部分进入 OmniKernel 分支进行多尺度与频域增强^[8]，另一部分通过恒等映射直接旁路，以在保证特征表达能力的同时控制计算开销。OmniKernel 分支通过多尺度卷积核与频域建模手段，能够同时捕获局部细节、长条结构以及大范围上下文信息，特别适合航空场景中尺度变化显著的小目标建模。




图 6 CSPO 模块结构及其多尺度与频域增强机制

通过 CSP 结构的引入，CSPO 在增强关键通道特征的同时保留了原始信息流，使得网络在多模态融合

与小目标增强之间取得良好的平衡。该模块与 SNI、SPDConv 协同工作，共同构成本文提出的软对齐小目标增强金字塔（SSOEP），有效提升了多模态检测框架在复杂场景下的小目标检测能力。

2.4 增强型 GSConvE 特征融合模块 (GSConvE)

在多模态目标检测框架中，自底向上的特征融合路径（PAN）主要负责将低层的空间细节信息逐步向高层语义特征传递，以弥补高层特征在定位精度上的不足。然而，在红外与可见光多模态融合场景下，该阶段的特征分布往往呈现出更强的异质性：一方面，不同模态在低层特征中包含的纹理、边缘与噪声成分差异显著；另一方面，经过前序融合与增强操作后，特征通道之间的信息相关性更加复杂。

传统 PAN 结构通常采用标准卷积对特征进行下采样与融合，该方式虽然实现简单，但在多模态场景下容易出现两个问题：其一，卷积核感受野单一，难以同时兼顾局部细节与上下文信息；其二，通道之间的信息交互不足，不同模态或不同尺度的特征响应可能在通道维度上被隔离，限制了融合效果。

2.4.1 GSConvE 模块结构设计

为提升自底向上特征融合阶段的表达能力，本文引入增强型 GSConvE 模块替代传统卷积操作。GSConvE 在 GSConv^[9] 结构的基础上进行扩展，通过双分支特征生成与通道重排机制，在较低计算开销下获得更加多样化的特征表征能力。其整体结构如图 7 所示。




图 7 增强型 GSConvE 模块结构

如图 7 所示，GSConvE 首先通过标准卷积对输入特征进行通道压缩与初步变换，随后将特征分为两条路径：主分支继续采用标准卷积进行特征映射，增强分支则引入深度可分离卷积以捕获更细粒度的空间结构信息。两条分支的输出在通道维度进行拼接，并通过通道重排（Channel Shuffle）操作促进不同分支、不同通道之间的信息交互。

相较于传统卷积结构，GSConvE 在多模态自底向上融合阶段具有以下优势。

(1) 双分支结构能够在同一模块内生成具有不同感受野特性的特征表示，使网络在传递低层信息时同时保留局部纹理细节与更具抽象性的结构信息。这一特性对于多模态特征尤为重要，有助于缓解单一模态主导或细节信息不足的问题。

(2) 深度可分离卷积的引入在增强特征表达能力的同时有效控制了计算复杂度，使 GSConvE 能够在保持整体网络高效性的前提下用于多尺度融合路径。相比完全采用标准卷积堆叠，该设计在计算效率与表示能力之间取得了更合理的平衡。

(3) 通道重排操作显式促进了不同分支及不同模态特征在通道维度上的信息混合，增强了跨通道的信息流动性，从而提升多模态融合特征的整体一致性与判别性。

3 实验与结果分析

3.1 数据集介绍

为全面验证本文所提出多模态目标检测方法在不同场景与数据分布下的有效性，实验选取了两个具有代表性的数据集进行评估：一个是真实多模态红外-可见光目标检测数据集 M3FD，另一个是典型的航空可见光遥感目标检测数据集 VEDAI512。这两个数据集在成像模态、场景类型以及目标尺度分布等方面均存在显著差异，能够从多角度验证所提出方法的泛化能力与鲁棒性。

(1) M3FD 多模态目标检测数据集。

M3FD 是一个面向红外与可见光多模态目标检测任务构建的数据集，包含严格配准的红外与可见光图像对。该数据集覆盖了多种典型复杂场景，包括城市场景、郊区环境以及光照条件变化明显的区域，同时在不同时间、不同天气条件下采集，具有较大的场景多样性。

在 M3FD 数据集中，红外模态能够提供稳定的目标热响应信息，而可见光模态则包含更丰富的纹理与结构细节。两种模态在目标显著性、背景干扰形式以及噪声分布方面具有明显互补特性，使该数据集成为评估多模态目标检测方法的重要基准。图 8 展示了 M3FD 数据集中部分红外与可见光样本示例。




图 8 M3FD 数据集红外与可见光图像样本示例

从图 8 可以看出，在弱光或复杂背景条件下，可见光模态中的目标容易受到环境干扰，而红外模态则能够提供更加稳定的目标响应；但在目标边缘与细节表达方面，红外图像相对模糊。该特性使得 M3FD 数据集对多模态特征融合能力与语义建模能力提出了更高要求。

(2) VEDAI512 航空遥感目标检测数据集。

VEDAI512 是基于 VEDAI 数据集构建的航空遥感目标检测数据集，主要包含多类别车辆目标，广泛应用于小目标检测与遥感场景目标识别研究。该数据集由高分辨率航空影像裁剪得到，图像分辨率统一为 512×512 ，目标尺度普遍较小，且分布密集，具有典型的小目标检测特征。

VEDAI512 数据集中的场景涵盖居民区、道路、停车场及自然背景区域，目标在尺度、方向以及背景复杂度方面变化较大，给检测算法在定位精度与类别判别方面带来了较大挑战。图 9 展示了 VEDAI512 数据集中部分可见光遥感图像样本。

由于目标尺寸较小且背景结构复杂，VEDAI512 数据集对特征金字塔结构、小目标增强策略以及多尺度特征融合能力具有较高要求。通过在该数据集上的实验，可以有效评估本文所提出方法在小目标检测任务中的适用性与泛化能力。

综合来看，M3FD 数据集侧重于验证多模态信息融合与复杂环境鲁棒性，而 VEDAI512 数据集则更强



图 9 VEDAI512 航空遥感图像样本示例

调航空遥感场景下的小目标检测能力。在这两个数据集上的联合实验，能够全面验证本文所提出多模态目标检测框架在不同模态组合与目标尺度分布条件下的有效性。

3.2 实验设置

为保证实验结果的公平性与可复现性，本文在统一的软硬件环境下对所提出方法进行训练与测试。所有实验均在 Linux 操作系统平台上完成，采用 PyTorch 深度学习框架进行实现。针对不同规模的数据集，设置了不同的训练轮数，以充分保证模型的收敛性。

对于规模较大的 M3FD 多模态数据集，训练轮数设置为 200；对于规模相对较小的 VEDAI512 数据集，训练轮数设置为 100。两组实验均采用相同的批大小与优化配置，以避免训练策略差异对实验结果产生影响。实验中未启用自动混合精度（AMP），以确保数值计算的一致性与稳定性。

表 1 实验环境与训练参数设置

项目	配置说明
操作系统	Linux
编程语言	Python 3.10.19
深度学习框架	PyTorch 2.2.0
CUDA 版本	CUDA 11.8
GPU 型号	NVIDIA A10
GPU 数量	4
单卡显存	24 GB
批大小 (Batch Size)	8
训练轮数 (M3FD)	200
训练轮数 (VEDAI512)	100
自动混合精度 (AMP)	未启用 (False)

3.3 评价指标

为全面评估本文所提出多模态目标检测方法的检测性能与计算复杂度, 实验采用 Precision、Recall、mAP@0.5、mAP@0.5:0.95 以及 GFLOPs 作为评价指标。其中, 前四项指标用于衡量检测精度与召回性能, GFLOPs 用于衡量模型的计算复杂度。

Precision (精确率) 与 Recall (召回率) 是目标检测中常用的基本评价指标, 分别反映模型预测结果的准确性与目标覆盖能力。其定义如下:

$$Precision = \frac{TP}{TP + FP}, \quad (1)$$

$$Recall = \frac{TP}{TP + FN}, \quad (2)$$

其中, TP 表示被正确检测的正样本数量, FP 表示被错误检测的负样本数量, FN 表示未被检测到的正样本数量。Precision 越高表示模型误检率越低, Recall 越高表示模型漏检情况越少。在复杂背景与小目标场景下, Precision 与 Recall 往往存在一定权衡关系, 因此需要结合其他指标进行综合评估。

平均精度均值 (mean Average Precision, mAP) 是目标检测任务中最常用的综合评价指标, 用于衡量模型在不同类别上的整体检测性能。本文采用 mAP@0.5 与 mAP@0.5:0.95 两种形式进行评估。

其中, mAP@0.5 表示在交并比 (Intersection over Union, IoU) 阈值为 0.5 时, 对各类别 Average Precision (AP) 求平均得到的结果, 主要反映模型在较宽松定位条件下的检测能力。

mAP@0.5:0.95 则是在 IoU 阈值从 0.5 到 0.95 (步长为 0.05) 范围内计算 AP 并取平均的结果, 该指标对目标定位精度要求更高, 能够更加全面地反映模型在不同尺度与定位精度要求下的综合检测性能。该指标通常被认为是更为严格和稳定的评价标准。

为评估模型在计算效率方面的表现, 本文采用 GFLOPs (Giga Floating Point Operations) 作为效率的衡量指标, 用于表示模型在一次前向推理过程中所需的浮点运算量。GFLOPs 数值越小, 说明模型计算复杂度越低, 越有利于在算力受限的实际应用场景中部署。

3.4 对比实验

表 2 不同方法在 M3FD 数据集上的检测性能对比

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
YOLOv5n	83.8	64.6	73.1	46.4	7.1
YOLOv8n	83.6	68.9	74.9	51.4	8.1
YOLOv10n	76.8	70.2	76.0	47.1	6.5
YOLOv11n	80.8	65.6	71.9	50.4	6.3
YOLOv12n	80.8	64.4	70.9	44.4	5.8
YOLOv13n	73.9	55.6	61.9	38.5	6.2
RT-DETR	87.2	81.0	81.2	55.0	57.0
MMDetection-DS	85.0	66.2	75.4	50.2	19.8
Ours	88.9	68.4	78.9	51.9	16.9

从表 2 可以看出，在 M3FD 多模态目标检测数据集上，本文提出的方法在多项指标上均取得了具有竞争力的性能。与多种 YOLO 系列轻量化模型相比，本文方法在 Precision 指标上取得了最高的 88.9%，表明所提出的多模态特征建模与门控机制能够有效降低误检率，提升检测结果的可靠性。

在 mAP50 与 mAP50-95 指标上，本文方法分别达到 78.9% 和 51.9%，显著优于大多数 YOLO 系列模型，说明所提出的多模态融合与小目标增强策略在整体检测性能与高精度定位方面均具有明显优势。相比于基于 Transformer 的 RT-DETR，本文方法在保持较高检测精度的同时，将计算复杂度从 57.0 GFLOPs 降低至 16.9 GFLOPs，在性能与效率之间取得了更为合理的平衡。

需要指出的是，RT-DETR 在 Recall 指标上具有一定优势，这主要得益于其全局建模能力；而本文方法通过引入 AGCSPB 与 SSOEP 模块，在保证较高召回率的同时进一步提升了检测精度，体现了多模态特征筛选与尺度增强策略的有效性。

表 3 不同方法在 VEDAI512 数据集上的检测性能对比

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
YOLOv8n	43.8	47.9	41.7	22.6	8.1
YOLOv9t	45.9	48.9	44.9	23.5	7.7
YOLOv10n	34.2	41.6	34.4	20.2	6.6
RT-DETR	55.4	53.6	49.3	27.6	57.0
Ours	54.3	56.9	49.1	27.1	16.9

在 VEDAI512 航空遥感小目标检测数据集上的对比结果如表 3 所示。可以观察到，本文方法在 Recall 指标上取得了最高的 56.9%，表明其在小目标场景下具有更强的目标覆盖能力，有效缓解了漏检问题。

在 mAP50 与 mAP50-95 指标上，本文方法与 RT-DETR 表现接近，但计算复杂度显著降低，仅为 16.9 GFLOPs，而 RT-DETR 达到 57.0 GFLOPs。这表明本文提出的小目标增强金字塔与高效特征融合模块在提升检测性能的同时，具有更好的计算效率，更适合在实际工程场景中部署。

与 YOLO 系列模型相比，本文方法在 Precision、Recall 以及 mAP 指标上均取得明显提升，验证了多模态特征融合与针对性结构改进在航空遥感小目标检测任务中的有效性。

3.5 消融实验

表 4 不同模块组合下的消融实验结果 (VEDAI512)

Model	P(%)	R(%)	mAP50(%)	mAP50-95(%)	GFLOPs
Baseline	40.1	48.0	43.6	23.5	6.3
Baseline+AGCSPB	39.6	46.9	45.4	23.0	10.3
Baseline+AGCSPB+SSOEP	41.4	55.8	48.2	26.0	16.2
Baseline+AGCSPB+SSOEP+GSConvE	54.3	56.9	49.1	27.1	16.9

为验证本文所提出各改进模块在多模态小目标检测任务中的有效性，本文在 VEDAI512 数据集上进行了系统的消融实验。以基线多模态检测框架为起点，逐步引入 AGCSPB、SSOEP 以及 GSConvE 模块，其

检测性能对比如表 4 所示。

首先，在基线模型上引入 AGCSPB 模块后，mAP50 指标由 43.6% 提升至 45.4%，表明注意力与门控机制有助于增强多模态特征的判别性表达。然而，由于该模块主要作用于高层语义建模阶段，对小目标的细粒度信息提升有限，因此 Recall 与 mAP50-95 指标提升不明显，同时计算量有所增加。

进一步在模型中引入 SSOEP 模块后，Recall 指标由 46.9% 显著提升至 55.8%，mAP50 与 mAP50-95 分别提升至 48.2% 和 26.0%。这一结果表明，小目标增强与尺度软对齐策略能够有效缓解多尺度特征融合过程中细节信息丢失的问题，对提升小目标检测性能具有关键作用。

在此基础上，加入 GSConvE 特征融合模块后，模型在 Precision、Recall 以及 mAP 指标上均取得进一步提升，其中 Precision 提升至 54.3%，mAP50-95 提升至 27.1%。与此同时，计算复杂度仅由 16.2 GFLOPs 增加至 16.9 GFLOPs，表明 GSConvE 在引入有限计算开销的前提下，有效增强了特征融合阶段的表达多样性与信息交互能力。

综合来看，各改进模块在整体框架中发挥了互补作用：AGCSPB 强化了多模态高层语义建模，SSOEP 显著提升了小目标特征的尺度对齐与表达能力，而 GSConvE 则在保证效率的同时进一步优化了特征融合效果，共同促成了模型整体性能的稳步提升。

3.6 定量评价结果分析

3.6.1 PR 曲线




图 10 M3FD 数据集上的 Precision-Recall 曲线

如图 10 所示，给出了本文方法在 M3FD 数据集上的 Precision-Recall (P-R) 曲线，其中同时绘制了各类别的 P-R 曲线以及整体平均曲线。可以观察到：

(1) 整体性能表现稳定

(2) 本文方法在大多数 Recall 区间内均保持较高的 Precision 水平，整体 P-R 曲线包围面积较大，最终获得 mAP@0.5 为 49.1%，表明模型在不同置信阈值下均具备较好的综合检测能力。

(3) 主流目标类别检测效果显著对于 *Car*、*Camping Van*、*Pickup* 等在多模态场景中出现频率较高的类别，其 P-R 曲线整体较为平滑且位于较高区域，说明模型在红外与可见光信息融合后，对此类目标具有稳定且可靠的判别能力。

(4) 小样本与外观多变类别仍具挑战性对于 *Others*、*Van* 等类别，其 P-R 曲线整体偏低，主要原因在于目标尺度较小、外观差异较大以及样本数量有限。尽管如此，本文方法相较基线模型在这些类别上仍表现出更高的 Recall 水平，体现了所提出多尺度增强与融合策略的有效性。

综合来看，P-R 曲线结果进一步验证了本文方法在多模态目标检测任务中具有良好的稳定性与鲁棒性。

3.6.2 可视化结果



图 11 M3FD 数据集上的多模态目标检测可视化结果

图 11 展示了本文方法在 M3FD 数据集上的部分检测结果可视化示例，其中每组样例同时给出了红外图像与可见光图像的检测结果。可以观察到以下几点：

(1) 复杂背景下的检测鲁棒性提升在农田、建筑群及道路等复杂背景场景中，目标与背景在单一模态下往往对比度较低。通过多模态特征融合，模型能够有效利用红外模态的热辐射信息与可见光模态的纹理结构信息，实现对目标区域的准确定位。

(2) 小目标与密集目标检测能力增强对于尺度较小或分布密集的车辆目标，本文方法能够在保持较高置信度的同时减少漏检现象。这一现象与前文提出的 SSOEP 小目标增强金字塔结构密切相关，其在多尺度特征融合阶段有效保留了细粒度空间信息。

(3) 多类别目标判别更加稳定在存在多种车辆类型共存的场景中，模型能够较好地地区分 *Car*、*Pickup*、*Camping Van* 等相似类别，误检与类别混淆现象明显减少。这表明 AGCSPB 与 GSConvE 模块在高层语义建模与特征融合方面起到了积极作用。

总体而言，定性结果与定量实验结论保持一致，进一步说明本文提出的多模态检测框架在复杂环境、小目标场景以及多类别共存条件下均具备较强的实用价值。

4 总结与展望

本文围绕复杂场景下红外-可见光多模态目标检测任务，针对航空视角中目标尺度小、背景复杂、多模态特征融合困难等问题，构建了一套基于 YOLO 单阶段检测框架的多模态目标检测方法，并在该框架基础上提出了多项具有针对性的结构改进。

本文在分析传统单模态检测方法及现有多模态检测框架局限性的基础上，构建了一个基线多模态目标检测框架，将红外与可见光信息通过并行 Backbone 进行特征提取，并在中高层特征阶段完成模态融合，为后续改进提供了统一的对照基准。该基线框架在保持 YOLO 系列模型高效推理特性的同时，使网络具备利用多模态互补信息的能力。

针对多模态特征建模能力不足的问题，本文提出了 Attention-Gated CSP Bottleneck (AGCSPB) 模块，通过在传统 CSP 结构中引入注意力与门控机制，有效增强了网络对关键语义特征的建模能力，提高了复杂背景下的目标判别能力。针对多尺度特征融合过程中小目标信息易丢失的问题，设计了 Soft-aligned Small Object Enhancement Pyramid (SSOEP)，通过软对齐上采样与空间重排策略，减轻了尺度错配带来的信息损失，显著提升了小目标检测性能。此外，为在保证计算效率的前提下提升特征融合质量，本文引入了增强型 GSConvE 模块，在自底向上的特征融合路径中增强了特征多样性与通道间信息交互能力。

在 M3FD 与 VEDAI512 两个具有代表性的多模态遥感数据集上的大量实验结果表明，本文方法在 Precision、Recall 以及 mAP 等关键指标上均取得了优于多种主流方法的检测性能。消融实验进一步验证了各改进模块在整体框架中的有效性与协同性，定性可视化结果也表明本文方法在复杂场景、小目标及多类别共存条件下具有更好的检测鲁棒性与稳定性。

尽管本文方法在多模态目标检测任务中取得了较为理想的效果，但仍存在一定的改进空间。未来的研究工作可从以下几个方面展开：一是进一步探索更加高效的跨模态特征对齐与交互机制，以减少模态差异带来的干扰；二是结合轻量化模型设计与模型压缩技术，进一步降低计算开销，提升方法在边缘设备上的部署能力；三是将所提出的方法拓展至更复杂的多源遥感场景或视频目标检测任务，以验证其在更广泛应用场景下的泛化能力。

综上所述，本文提出的多模态目标检测方法在性能与效率之间取得了较好的平衡，为复杂环境下的多模态航空目标检测提供了一种有效的解决思路。

参考文献

- [1] Song Xiaogang, Tan Yuping, Guo Fuqiang, et al. Cross-modal feature fusion and detail information enhancement for RGB-D salient object detection. Chinese Journal of Image and Graphics, 2025, 30(12): 3838–3854 (in Chinese)
(宋霄罡, 谭裕平, 郭富强, 等. 跨模态特征融合与细节信息增强的 RGB-D 显著目标检测. 中国图象图形学报, 2025, 30(12): 3838–3854)
- [2] Yuan Haoming, Xie Liang, Zhang Yilong. RGBD-SAM: A progressive fusion weakly supervised salient object detection method. Journal of Chinese Computer Systems, 2025: 1–10.
DOI: 10.20009/j.cnki.21-1106/TP.2025-0341
(袁浩铭, 谢亮, 张怡龙. RGBD-SAM: 一种渐进式融合的弱监督显著性目标检测方法. 小型微型计算机系统, 2025: 1–10)

-
- [3] Wu Yiwen, Tan Jieqing. Research on remote sensing small object detection algorithm based on multimodal fusion. *Computer Knowledge and Technology*, 2025, 21(33): 14–17 (in Chinese)
(武亦文, 檀结庆. 基于多模态融合的遥感小目标检测算法研究. *电脑知识与技术*, 2025, 21(33): 14–17)
- [4] Feng Xiao, Gong Weiwei, Sun Xiang'e. UAV small object detection based on dual-modal image fusion. *Laser & Optoelectronics Progress*, 2025, 62(22): 325–333 (in Chinese)
(冯潇, 龚维维, 孙祥娥. 基于双模态图像融合的无人机小目标检测. *激光与光电子学进展*, 2025, 62(22): 325–333)
- [5] Yao Jilin, Liu Hongzhe, Zhang Cheng, et al. UAV small object detection method based on multimodal fusion network. *Computer Engineering and Applications*, 2025: 1–12.
Available online: <https://link.cnki.net/urlid/11.2127.tp.20251028.1636.012>
(姚继林, 刘宏哲, 张铖, 等. 基于多模态融合网络的无人机小目标检测方法. *计算机工程与应用*, 2025: 1–12)
- [6] Yu Zhirui, Yin Zhanpeng, Wang Junyu, et al. Multimodal object detection method with adaptive fusion of visible and infrared features. *Journal of Remote Sensing*, 2025, 29(10): 3006–3019 (in Chinese)
(喻智睿, 尹展鹏, 王俊宇, 等. 可见光和红外特征自适应融合的多模态目标检测方法. *遥感学报*, 2025, 29(10): 3006–3019)
- [7] Dai Xiaobo, Ren Siyu, He Xiaohai, et al. Visible–infrared image fusion object detection based on feature enhancement and alignment. *Journal of Engineering Science*, 2025, 47(12): 2554–2565 (in Chinese)
DOI: 10.13374/j.issn2095-9389.2025.03.26.004
(代小波, 任思羽, 何小海, 等. 基于特征增强和对齐融合的可见光–红外图像融合目标检测. *工程科学学报*, 2025, 47(12): 2554–2565)
- [8] Cui Y, Ren W, Knoll A. Omni-kernel network for image restoration. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024, 38(2): 1426–1434
- [9] Li H. Rethinking features-fused-pyramid-neck for object detection. In: *European Conference on Computer Vision*. Cham: Springer Nature Switzerland, 2024: 74–90