

## 数据分析与可视化

项目背景：公司有一家小型口罩工厂，口罩厂从 2020 年初开始售卖口罩，在今年 6 月底开始处于亏损状态

任务：对历史经营数据进行分析，找到亏损原因，并结合公司实际情况提供对应的解决策略。

步骤一：读取口罩厂数据 `mask_data.csv`，并查看 `mask_data`。

提示：`pd.read_csv(path, encoding)` 就是一种高效读取 `csv` 文件的方法，返回的是一个 `DataFrame` 对象。

由于本题中所给出的 `csv` 数据文件的格式为“`utf-8`”，故：

# 导入 `csv` 数据

```
my_data = pd.read_csv(path, encoding = 'utf-8')
```

步骤二：对这份数据进行如下清洗：

1) 处理缺失值

2) 处理重复值

3) 处理异常值（提示：先用布尔索引处理（3），再处理（1））

（1）订单量的最小值几乎是 0

在实际业务中，不可能出现订单量为 0 的情况，所以订单量等于 0 的数据属于异常值。

（2）订单量的最大值几乎是 10 的九次方

10 个亿的订单量我司口罩厂的产能明显无法跟上，所以这种极大的数据也属于异常值。

（3）单价的最大值也几乎是 10 的九次方

公司每盒口罩的单价最高 200 元，大于 200 的数据都属于异常值。

步骤三：对这份数据进行如下整理：

为了分析口罩厂各个月的利润变化情况，需要将日期的统计数据由年-月-日调整为月，然后作为新的月份字段保存到数据中。

提示：数据整理分成三个步骤，它们分别是：转换日期数据（采用 `pd.to_datetime(arg, format)` 函数）、提取月份信息（采用 `Series.dt.month`）以及添加新列。

#### 步骤四：数据写入

使用 `df.to_csv()` 方法，将清洗好的数据写入到 `csv` 文件中。

#### 步骤五：数据可视化展示

1. 分别绘制各月的总销售额、总订单量、平均单价以及各省在各月总订单量，并进行分析。
2. 根据销售额、订单量、口罩单价、订单来源省份的影响因素以及月的时间维度进行分析，并通过作图查看各个数据的对比和趋势，最终发现数据变化的规律和原因。
3. 除了分析口罩厂内部的数据，还可以结合外部环境数据去佐证我们的结论。

